

# Introdução à Classificação de Padrões

**Guilherme de Alencar Barreto**

`gbarreto@ufc.br`

Grupo de Aprendizado de Máquinas – GRAMA  
Departamento de Engenharia de Teleinformática  
Universidade Federal do Ceará – UFC  
<http://lattes.cnpq.br/8902002461422112>

## Pré-Requisitos

- ① Noções de Álgebra Linear
- ② Noções de Geometria Analítica
- ③ Noções de Funções
- ④ Noções de Limites

## Objetivo Geral

Apresentar vários classificadores baseados em medidas de dissimilaridade e seu amplo uso em reconhecimento de padrões, bem como relações com medidas de similaridade e o conceito de métrica.

## Conteúdo dos Slides

- 1 O Que é Ser Inteligente?
- 2 Inteligência e Reconhecimento de Padrões
- 3 Conceituação Intuitiva do Problema
- 4 Um Computador pode Reconhecer Padrões?
- 5 Componentes de um Problema de Classificação
- 6 Classificadores Elementares (NN e Centróide)
- 7 Medidas de (Dis-)similaridade
- 8 Técnicas de Normalização dos Dados
- 9 Correlação e Matriz de Covariância
- 10 Classificador Quadrático

### O Que é Ser Inteligente?

- Seria ter habilidade específicas em certos domínios do conhecimento?

*(e.g. ser um neurocirurgião)*

### O Que é Ser Inteligente?

- Seria ter habilidade específicas em certos domínios do conhecimento?  
*(e.g. ser um neurocirurgião)*
- Ou resolver problemas genéricos de modo aproximado, porém satisfatório?  
*(e.g. achar vaga em estacionamento)*

### O Que é Ser Inteligente?

- Seria ter habilidade específicas em certos domínios do conhecimento?  
*(e.g. ser um neurocirurgião)*
- Ou resolver problemas genéricos de modo aproximado, porém satisfatório?  
*(e.g. achar vaga em estacionamento)*
- Ou ainda: ter conhecimento enciclopédico?  
*(e.g. ser um erudito)*

### O Que é Ser Inteligente?

- Seria ter habilidade específicas em certos domínios do conhecimento?  
*(e.g. ser um neurocirurgião)*
- Ou resolver problemas genéricos de modo aproximado, porém satisfatório?  
*(e.g. achar vaga em estacionamento)*
- Ou ainda: ter conhecimento enciclopédico?  
*(e.g. ser um erudito)*
- Tocar um instrumento? Falar outras línguas? Jogar bola bem?

### Inteligência e Reconhecimento de Padrões

- Seres vivos são habilidosos em reconhecer diversos padrões:
  - ➊ Comportamentais (fulano age sempre assim!)

### Inteligência e Reconhecimento de Padrões

- Seres vivos são habilidosos em reconhecer diversos padrões:
  - ➊ Comportamentais (fulano age sempre assim!)
  - ➋ Sonoros (Este barulho não é normal!)

### Inteligência e Reconhecimento de Padrões

- Seres vivos são habilidosos em reconhecer diversos padrões:
  - ➊ Comportamentais (fulano age sempre assim!)
  - ➋ Sonoros (Este barulho não é normal!)
  - ➌ Táteis (Estes tecidos têm texturas distintas!)

### Inteligência e Reconhecimento de Padrões

- Seres vivos são habilidosos em reconhecer diversos padrões:
  - ➊ Comportamentais (fulano age sempre assim!)
  - ➋ Sonoros (Este barulho não é normal!)
  - ➌ Táteis (Estes tecidos têm texturas distintas!)
  - ➍ Visuais (Acho que vai chover hoje!)

### Inteligência e Reconhecimento de Padrões

- Seres vivos são habilidosos em reconhecer diversos padrões:
  - ➊ Comportamentais (fulano age sempre assim!)
  - ➋ Sonoros (Este barulho não é normal!)
  - ➌ Táteis (Estes tecidos têm texturas distintas!)
  - ➍ Visuais (Acho que vai chover hoje!)
  - ➎ Olfativos (De quem é esse perfume?)

### Inteligência e Reconhecimento de Padrões

- Seres vivos são habilidosos em reconhecer diversos padrões:
  - ① Comportamentais (fulano age sempre assim!)
  - ② Sonoros (Este barulho não é normal!)
  - ③ Táteis (Estes tecidos têm texturas distintas!)
  - ④ Visuais (Acho que vai chover hoje!)
  - ⑤ Olfativos (De quem é esse perfume?)
  - ⑥ Numéricos (Quem pegou um dos doces?)

### Inteligência e Reconhecimento de Padrões

- Seres vivos são habilidosos em reconhecer diversos padrões:
  - ❶ Comportamentais (fulano age sempre assim!)
  - ❷ Sonoros (Este barulho não é normal!)
  - ❸ Táteis (Estes tecidos têm texturas distintas!)
  - ❹ Visuais (Acho que vai chover hoje!)
  - ❺ Olfativos (De quem é esse perfume?)
  - ❻ Numéricos (Quem pegou um dos doces?)

### Definição Informal de Reconhecimento de Padrões

Reconhecer padrões equivale a categorizar determinado objeto físico ou situação como pertencente (ou não) a um certo número de categorias previamente estabelecidas.

### Inteligência e Reconhecimento de Padrões



(a) Grupo 1



(b) Grupo 2



(c) Grupo 3

Em qual dos grupos acima você colocaria o objeto abaixo:



### Um Computador Pode Reconhecer Padrões?

- Certamente, a sua decisão é tomada com base no **grau de similaridade** entre a fruta desconhecida e as frutas conhecidas.

### Um Computador Pode Reconhecer Padrões?

- Certamente, a sua decisão é tomada com base no **grau de similaridade** entre a fruta desconhecida e as frutas conhecidas.
- Que mecanismo seu cérebro usa para realizar esta tarefa?

### Um Computador Pode Reconhecer Padrões?

- Certamente, a sua decisão é tomada com base no **grau de similaridade** entre a fruta desconhecida e as frutas conhecidas.
- Que mecanismo seu cérebro usa para realizar esta tarefa?
- Será que implementa uma comparação entre o objeto novo e objetos armazenados?

### Um Computador Pode Reconhecer Padrões?

- Certamente, a sua decisão é tomada com base no **grau de similaridade** entre a fruta desconhecida e as frutas conhecidas.
- Que mecanismo seu cérebro usa para realizar esta tarefa?
- Será que implementa uma comparação entre o objeto novo e objetos armazenados?
- É possível “replicar” este mecanismo em uma máquina???

### Um Computador Pode Reconhecer Padrões?



Figura : Alan Turing (23/06/1912 – 07/06/1954)<sup>a</sup>

---

<sup>a</sup> A. Turing (1950). “Computing Machinery and Intelligence”, *Mind*, vol. LIX, no. 236, p. 433–460. Disponível em <https://academic.oup.com/mind/article/LIX/236/433/986238>

### Um Computador Pode Reconhecer Padrões?

- Para comparar objetos precisamos de

### Um Computador Pode Reconhecer Padrões?

- Para comparar objetos precisamos de
  - Uma **representação** dos atributos físicos das frutas.

### Um Computador Pode Reconhecer Padrões?

- Para comparar objetos precisamos de
  - Uma **representação** dos atributos físicos das frutas.
  - Uma **memória** para armazenar as frutas já aprendidas.

### Um Computador Pode Reconhecer Padrões?

- Para comparar objetos precisamos de
  - Uma **representação** dos atributos físicos das frutas.
  - Uma **memória** para armazenar as frutas já aprendidas.
  - Uma **regra de decisão** para classificar frutas.

### Um Computador Pode Reconhecer Padrões?

- Para comparar objetos precisamos de
  - Uma **representação** dos atributos físicos das frutas.
  - Uma **memória** para armazenar as frutas já aprendidas.
  - Uma **regra de decisão** para classificar frutas.
  - Um **aprendizado** para introduzir novas frutas.

### Um Computador Pode Reconhecer Padrões?

- Quais são os atributos que descrevem a tangerina?

### Um Computador Pode Reconhecer Padrões?

- Quais são os atributos que descrevem a tangerina?
  - ➊ Qual seu formato?

### Um Computador Pode Reconhecer Padrões?

- Quais são os atributos que descrevem a tangerina?
  - ① Qual seu formato?
  - ② É uma fruta cítrica?

### Um Computador Pode Reconhecer Padrões?

- Quais são os atributos que descrevem a tangerina?
  - ① Qual seu formato?
  - ② É uma fruta cítrica?
  - ③ Qual a sua cor?

### Um Computador Pode Reconhecer Padrões?

- Quais são os atributos que descrevem a tangerina?
  - ① Qual seu formato?
  - ② É uma fruta cítrica?
  - ③ Qual a sua cor?
  - ④ Qual a textura da casca?

### Um Computador Pode Reconhecer Padrões?

- Quais são os atributos que descrevem a tangerina?
  - ① Qual seu formato?
  - ② É uma fruta cítrica?
  - ③ Qual a sua cor?
  - ④ Qual a textura da casca?
  - ⑤ Seu cheiro é ativo ou não?

### Um Computador Pode Reconhecer Padrões?

- Quais são os atributos que descrevem a tangerina?
  - ① Qual seu formato?
  - ② É uma fruta cítrica?
  - ③ Qual a sua cor?
  - ④ Qual a textura da casca?
  - ⑤ Seu cheiro é ativo ou não?
- Todos esses atributos são igualmente importantes?

### Um Computador Pode Reconhecer Padrões?

- Quais são os atributos que descrevem a tangerina?
  - ① Qual seu formato?
  - ② É uma fruta cítrica?
  - ③ Qual a sua cor?
  - ④ Qual a textura da casca?
  - ⑤ Seu cheiro é ativo ou não?
- Todos esses atributos são igualmente importantes?
- Quão difícil é a tarefa de definir os atributos de um objeto?

### Um Computador Pode Reconhecer Padrões?

- Respondendo às perguntas anteriores para a tangerina:

### Um Computador Pode Reconhecer Padrões?

- Respondendo às perguntas anteriores para a tangerina:
  - ➊ Oval.

### Um Computador Pode Reconhecer Padrões?

- Respondendo às perguntas anteriores para a tangerina:
  - ➊ Oval.
  - ➋ Cítrico.

### Um Computador Pode Reconhecer Padrões?

- Respondendo às perguntas anteriores para a tangerina:
  - ➊ Oval.
  - ➋ Cítrico.
  - ➌ Alaranjada.

### Um Computador Pode Reconhecer Padrões?

- Respondendo às perguntas anteriores para a tangerina:
  - ➊ Oval.
  - ➋ Cítrico.
  - ➌ Alaranjada.
  - ➍ Rugosa.

### Um Computador Pode Reconhecer Padrões?

- Respondendo às perguntas anteriores para a tangerina:
  - ➊ Oval.
  - ➋ Cítrico.
  - ➌ Alaranjada.
  - ➍ Rugosa.
  - ➎ Ativo.

### Um Computador Pode Reconhecer Padrões?

- Respondendo às perguntas anteriores para a tangerina:
  - ➊ Oval.
  - ➋ Cítrico.
  - ➌ Alaranjada.
  - ➍ Rugosa.
  - ➎ Ativo.
- Provavelmente não!

### Um Computador Pode Reconhecer Padrões?

- Respondendo às perguntas anteriores para a tangerina:
  - ➊ Oval.
  - ➋ Cítrico.
  - ➌ Alaranjada.
  - ➍ Rugosa.
  - ➎ Ativo.
- Provavelmente não!
- Horrivelmente árdua! :-(

### Um Computador Pode Reconhecer Padrões?

- Porém, um computador só entende números!!

### Um Computador Pode Reconhecer Padrões?

- Porém, um computador só entende números!!
- Como transformar os atributos físicos da tangerina em números?

### Um Computador Pode Reconhecer Padrões?

- Porém, um computador só entende números!!
- Como transformar os atributos físicos da tangerina em números?
- Temos que representar cada objeto como um vetor de  $p$  atributos numéricos!

$$\mathbf{x} = [x_1 \ x_2 \ \cdots \ x_p]^T$$

### Um Computador Pode Reconhecer Padrões?

- Porém, um computador só entende números!!
- Como transformar os atributos físicos da tangerina em números?
- Temos que representar cada objeto como um vetor de  $p$  atributos numéricos!

$$\mathbf{x} = [x_1 \ x_2 \ \cdots \ x_p]^T$$

### Um Computador Pode Reconhecer Padrões?

- Porém, um computador só entende números!!
- Como transformar os atributos físicos da tangerina em números?
- Temos que representar cada objeto como um vetor de  $p$  atributos numéricos!

$$\mathbf{x} = [x_1 \ x_2 \ \cdots \ x_p]^T$$

- Assim, o objeto (tangerina) será representado como

$$\mathbf{x} = [0 \ 1 \ 2 \ 1 \ 1]^T$$

### Um Computador Pode Reconhecer Padrões?

- Para isso, foi definida e utilizada a seguinte convenção:

### Um Computador Pode Reconhecer Padrões?

- Para isso, foi definida e utilizada a seguinte convenção:

$x_1$ : {esférico, oval, alongado} = {0, 1, 2}.

### Um Computador Pode Reconhecer Padrões?

- Para isso, foi definida e utilizada a seguinte convenção:

$x_1$ : {esférico, oval, alongado} = {0, 1, 2}.

$x_2$ : {não, sim} = {0, 1}

### Um Computador Pode Reconhecer Padrões?

- Para isso, foi definida e utilizada a seguinte convenção:

$x_1$ : {esférico, oval, alongado} = {0, 1, 2}.

$x_2$ : {não, sim} = {0, 1}

$x_3$ : {amarelo, vermelho, alaranjado, verde, marrom} = {0, 1, 2, 3, 4}

### Um Computador Pode Reconhecer Padrões?

- Para isso, foi definida e utilizada a seguinte convenção:

$x_1$ : {esférico, oval, alongado} = {0, 1, 2}.

$x_2$ : {não, sim} = {0, 1}

$x_3$ : {amarelo, vermelho, alaranjado, verde, marrom} = {0, 1, 2, 3, 4}

$x_4$ : {lisa, rugosa, espinhosa} = 0,1,2

### Um Computador Pode Reconhecer Padrões?

- Para isso, foi definida e utilizada a seguinte convenção:

$x_1$ : {esférico, oval, alongado} = {0, 1, 2}.

$x_2$ : {não, sim} = {0, 1}

$x_3$ : {amarelo, vermelho, alaranjado, verde, marrom} = {0, 1, 2, 3, 4}

$x_4$ : {lisa, rugosa, espinhosa} = 0,1,2

$x_5$ : {não, sim} = {0, 1}

### Um Computador Pode Reconhecer Padrões?

- Para isso, foi definida e utilizada a seguinte convenção:

$x_1$ : {esférico, oval, alongado} = {0, 1, 2}.

$x_2$ : {não, sim} = {0, 1}

$x_3$ : {amarelo, vermelho, alaranjado, verde, marrom} = {0, 1, 2, 3, 4}

$x_4$ : {lisa, rugosa, espinhosa} = 0,1,2

$x_5$ : {não, sim} = {0, 1}

- Note que os atributos devem descrever também outras frutas.

### Um Computador Pode Reconhecer Padrões?

- Usando a convenção estabelecida para os atributos:

### Um Computador Pode Reconhecer Padrões?

- Usando a convenção estabelecida para os atributos:
  - **Objeto Laranja:**  $x = [0 \ 1 \ 2 \ 1 \ 0]$

### Um Computador Pode Reconhecer Padrões?

- Usando a convenção estabelecida para os atributos:
  - **Objeto Laranja:**  $x = [0 \ 1 \ 2 \ 1 \ 0]$
  - **Objeto Maçã:**  $y = [0 \ 0 \ 1 \ 0 \ 0]$

### Um Computador Pode Reconhecer Padrões?

- Usando a convenção estabelecida para os atributos:
  - **Objeto Laranja:**  $x = [0 \ 1 \ 2 \ 1 \ 0]$
  - **Objeto Maçã:**  $y = [0 \ 0 \ 1 \ 0 \ 0]$
  - **Objeto Tangerina:**  $z = [0 \ 1 \ 2 \ 1 \ 1]$

### Um Computador Pode Reconhecer Padrões?

- Usando a convenção estabelecida para os atributos:
  - **Objeto Laranja:**  $x = [0 \ 1 \ 2 \ 1 \ 0]$
  - **Objeto Maçã:**  $y = [0 \ 0 \ 1 \ 0 \ 0]$
  - **Objeto Tangerina:**  $z = [0 \ 1 \ 2 \ 1 \ 1]$
- O objeto **z** se assemelha mais a **x** ou a **y**? Ou seja,

### Um Computador Pode Reconhecer Padrões?

- Usando a convenção estabelecida para os atributos:
  - **Objeto Laranja:**  $x = [0 \ 1 \ 2 \ 1 \ 0]$
  - **Objeto Maçã:**  $y = [0 \ 0 \ 1 \ 0 \ 0]$
  - **Objeto Tangerina:**  $z = [0 \ 1 \ 2 \ 1 \ 1]$
- O objeto  $z$  se assemelha mais a  $x$  ou a  $y$ ? Ou seja,
  - $z = [0 \ 1 \ 2 \ 1 \ 1]$  está mais próximo de  $x = [0 \ 1 \ 2 \ 1 \ 0]$ ?

### Um Computador Pode Reconhecer Padrões?

- Usando a convenção estabelecida para os atributos:
  - **Objeto Laranja:**  $x = [0 \ 1 \ 2 \ 1 \ 0]$
  - **Objeto Maçã:**  $y = [0 \ 0 \ 1 \ 0 \ 0]$
  - **Objeto Tangerina:**  $z = [0 \ 1 \ 2 \ 1 \ 1]$
- O objeto  $z$  se assemelha mais a  $x$  ou a  $y$ ? Ou seja,
  - $z = [0 \ 1 \ 2 \ 1 \ 1]$  está mais próximo de  $x = [0 \ 1 \ 2 \ 1 \ 0]$ ?
  - Ou o objeto  $z$  está mais próximo de  $y = [0 \ 0 \ 1 \ 0 \ 0]$ ?

### Componentes de um Problema de Classificação

Considere um conjunto de dados de treinamento  $\mathcal{X}$  formado por vetores de atributos e seus respectivos rótulos

$$\mathcal{X} = \{(\mathbf{x}_n, \omega_n)\}_{n=1}^N \subset \mathbb{R}^p \times \Omega \quad (1)$$

em que

- $p$  é a dimensão do vetor de atributos.
- $K$  é o número de classes.
- $\Omega = \{\omega_1, \omega_2, \dots, \omega_K\}$  é um conjunto finito de  $K$  rótulos (não necessariamente numéricos) associados às  $K$  classes do problema.
- $N$  é o número de exemplos de treinamento, ou seja, a cardinalidade de  $\mathcal{X}$ :  $card(\mathcal{X}) = \#\mathcal{X} = N$

Classificador Vizinho Mais Próximo (NN, sigla em Inglês)

**Passo 1** - Armazenar em disco ou memória todo o conjunto  $\mathcal{X}$ , no formato adequado.

**Passo 2** - Para cada novo vetor de atributos  $\mathbf{x}$  ainda não-classificado, realizar uma busca em  $\mathcal{X}$  pelo índice do vetor de atributos mais próximo de  $\mathbf{x}$ :

$$i^* = \arg \min_{i=1,\dots,N} \|\mathbf{x} - \mathbf{x}_i\|^2 \quad (2)$$

em que  $\|\mathbf{v}\|$  denota a norma euclidiana do vetor  $\mathbf{v}$ .

**Passo 3** - Atribuir a  $\mathbf{x}$  a mesma classe que  $\mathbf{x}_{i^*}$ .

### Classificador Vizinho Mais Próximo (NN, sigla em Inglês)

- Alternativamente, os Passos 2 e 3 pode ser unificados e reescritos como um único passo da seguinte maneira:

Passo 2 Atribuir a  $\mathbf{x}$  a mesma classe que  $\mathbf{x}_{i^*}$ , se

$$\|\mathbf{x} - \mathbf{x}_{i^*}\|^2 < \|\mathbf{x} - \mathbf{x}_i\|^2, \quad \forall i \neq i^* \quad (3)$$

- Nas Expressões (2) e (3) usa-se a norma euclidiana quadrática, por dois motivos: (i) evitar o cálculo da raiz quadrada para ter a norma do vetor argumento. (ii) O valor mínimo (ou máximo) de uma função não se altera se a ela for aplicada uma operação matemática monotônica.
- Por exemplo, o mínimo da função  $f(x) = |x|$  é o mesmo que o da função  $g(x) = [f(x)]^2$ .

### Classificador Centróide Mais Próximo (MDC, sigla em Inglês)

**Passo 1** - Encontrar o vetor centróide de cada classe:

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{\forall \mathbf{x} \in \omega_i} \mathbf{x} \quad (4)$$

em que  $N_i$  é o número de exemplos da  $i$ -ésima classe (cujo rótulo é  $\omega_i$ ),  $i = 1, \dots, K$ .

**Passo 2** - Atribuir a  $\mathbf{x}$  a mesma classe que  $\mathbf{m}_{i^*}$ , se


$$\|\mathbf{x} - \mathbf{m}_{i^*}\|^2 < \|\mathbf{x} - \mathbf{m}_i\|^2, \quad \forall i \neq i^* \quad (5)$$

em que  $\|\mathbf{v}\|$  denota a norma euclidiana do vetor  $\mathbf{v}$ .

# Classificação de Padrões e Medidas de Dissimilaridade

## Classificadores Baseados em Distância Mínima

- Diagrama de fluxo de sinais para o classificador MDC para um problema de  $K$  classes.



- É possível notar que o cálculo de distâncias é muito importante para os dois classificadores mencionados anteriormente (NN e MDC).
- Em geral, utiliza-se norma euclidiana em seus algoritmos, mas existem várias outras normas que podem ser utilizadas.
- O conhecimento destas normas é de suma importância em reconhecimento de padrões, bem como as suas interpretações geométricas.
- A seguir vamos primeiro definir formalmente uma medida de dissimilaridade (i.e. distância) e suas propriedades, para depois listar algumas que são comumente usadas em classificação e clusterização de dados.

### Definição: Medidas de Dissimilaridade

- Se  $d_{rs}$  é uma medida de dissimilaridade entre os objetos<sup>a</sup>  $r$  e  $s$ , então deve satisfazer as seguintes condições:
  - 1  $d_{rs} \geq 0$ , para todo  $r, s$ .
  - 2  $d_{rr} = 0$ , para todo  $r$ .
  - 3  $d_{rs} = d_{sr}$ , para todo  $r, s$ .
- A condição 3 (simetria) nem sempre é satisfeita por certas medidas de dissimilaridade usuais (e.g. divergente de Kullback-Liebler).

---

<sup>a</sup>Tais objetos podem ser vetores, por exemplo. Ou nuvens (distribuições) de pontos.

- **Exemplo:** se a dissimilaridade entre dois lugares em uma cidade é medida pela distância percorrida por carro, então por causa de sistemas de mão única, a distância em um sentido pode ser mais longo do que a percorrida no outro.
- **Medidas de dissimilaridade** são aquelas que quanto mais próximos os objetos, menor são seus valores. Pra encurtar, dizemos que são medidas do tipo quanto menor, mais similar!
- **Medidas de similaridade** são aquelas que quanto mais próximos os objetos, maior são seus valores. Pra encurtar, dizemos que são medidas do tipo quanto maior, mais similar!

### Dissimilaridade vs. Similaridade

- Medidas de dissimilaridade podem ser transformadas em medidas de similaridade usando várias transformações.
- Se  $d_{ij}$  é uma medida de dissimilaridade entre os objetos  $i$  e  $j$ , uma medida de similaridade correspondente ( $s_{ij}$ ) pode ser definida como

$$s_{ij} = \frac{1}{1 + d_{ij}} \quad (6)$$

ou como

$$s_{ij} = c - d_{ij} \quad (7)$$

onde  $c$  é uma constante positiva.

### Definição: Métrica

- Se além das 3 condições discutidas anteriormente, a medida de dissimilaridade também satisfaz a desigualdade triangular

$$d_{rs} \leq d_{rt} + d_{ts}, \quad \forall r, s, t \quad (8)$$

então a medida de dissimilaridade é uma *métrica* e o termo *distância* é normalmente adotado.

- Em Matemática, métrica é um conceito que generaliza a ideia geométrica de distância.
- Um conjunto em que há uma métrica definida recebe o nome de espaço métrico.

# Classificação de Padrões e Medidas de Dissimilaridade

## Variáveis Numéricas

Definição: Distância de Minkowski de Ordem  $m$

- A *distância de Minkowski* é uma medida de dissimilaridade bem geral, a partir da qual podemos obter algumas das medidas de dissimilaridade mais comuns em RP.
- Sejam dois vetores reais  $\mathbf{x} = [x_1 \ x_2 \ \cdots \ x_p]^T$  e  $\mathbf{y} = [y_1 \ y_2 \ \cdots \ y_p]^T$ ; ou seja,  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ .
- A distância de Minkowski de ordem  $m$  entre  $\mathbf{x}$  e  $\mathbf{y}$  é definida pela seguinte expressão:

$$d_M^{(m)}(\mathbf{x}, \mathbf{y}) = \left( \sum_{j=1}^p |x_j - y_j|^m \right)^{\frac{1}{m}} \quad (9)$$

onde  $x_j$  e  $y_j$  são as  $j$ -ésimas componentes de  $\mathbf{x}$  e  $\mathbf{y}$ , respectivamente.



Se  $m = 1 \Rightarrow$  Distância Quarteirão

- Se fizermos  $m = 1$  na Equação (9) obtemos a expressão da distância quarteirão (*city block*, em Inglês):

$$d_{cb}(\mathbf{x}, \mathbf{y}) = |\mathbf{x} - \mathbf{y}| \quad (10)$$

$$= \sum_{j=1}^p |x_j - y_j| \quad (11)$$

$$= |x_1 - y_1| + \cdots + |x_p - y_p| \quad (12)$$

# Classificação de Padrões e Medidas de Dissimilaridade

## Variáveis Numéricas

Se  $m = 2 \Rightarrow$  Distância Euclidiana

- Se fizermos  $m = 2$  na Equação (9) obtemos a conhecida expressão da distância euclidiana:

$$d_e(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\| \quad (13)$$

$$= \left( \sum_{j=1}^p |x_j - y_j|^2 \right)^{\frac{1}{2}} \quad (14)$$

$$= \sqrt{\sum_{j=1}^p |x_j - y_j|^2} \quad (15)$$

$$= \sqrt{|x_1 - y_1|^2 + \cdots + |x_p - y_p|^2} \quad (16)$$

Se  $m \rightarrow \infty \Rightarrow$  Distância de Chebyshev

- Se fizermos  $m \rightarrow \infty$  na Equação (9) obtemos a expressão da distância de Chebyshev:

$$d_{ch}(\mathbf{x}, \mathbf{y}) = \lim_{m \rightarrow \infty} \left( \sum_{j=1}^p |x_j - y_j|^m \right)^{\frac{1}{m}} \quad (17)$$

$$= \max\{|x_1 - y_1|, \dots, |x_p - y_p|\} \quad (18)$$

$$= \max_i |x_i - y_i| \quad (19)$$

### Desafio!

Demonstrar a passagem da expressão mostrada na Equação (15) para a da Equação (16), tanto computacionalmente quanto matematicamente.


### Por que tantas medidas de dissimilaridade?

- Como vimos, existem muitas medidas de dissimilaridade e continuam sendo propostas novas a cada momento.
- A escolha de uma métrica particular depende da aplicação.
- Para fins de seleção/extracão de atributos deve-se escolher a métrica que leva ao melhor desempenho do classificador.
- Caso as métricas conduzam a desempenhos semelhantes, a escolha de qual usar pode ser feita com base no custo computacional para sua implementação.

# Classificação de Padrões e Medidas de Dissimilaridade

## Lugares Geométricos (curvas de contorno)

- A escolha da métrica deve levar em conta também a organização espacial (i.e. distribuição) dos dados.
- A figura abaixo ilustra as curvas de contorno geradas para as distâncias quarteirão, euclidiana e de Chebyshev.



### Distância Quadrática

- A distância quadrática, também chamada de distância de Mahalanobis, é outra medida de dissimilaridade muito utilizada em RP.
- Sua expressão geral é dada por

$$d_q(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^T \mathbf{Q} (\mathbf{x} - \mathbf{y})} \quad (20)$$

$$= \sqrt{\sum_{i=1}^p \sum_{j=1}^p (x_i - y_i) Q_{ij} (x_j - y_j)} \quad (21)$$

onde  $\mathbf{Q} = [Q_{ij}]_{p \times p}$  é uma matriz  $p \times p$  positiva definida.

### Distância Quadrática: Algumas considerações

- Uma matriz  $\mathbf{A}$  é definida positiva se, para qualquer vetor  $\mathbf{v}$ , obtermos sempre

$$\mathbf{v}^T \mathbf{A} \mathbf{v} > 0 \quad (22)$$

- Assim, a matriz  $\mathbf{Q}$  deve ser positiva definida para que o termo  $(\mathbf{x} - \mathbf{y})^T \mathbf{Q}(\mathbf{x} - \mathbf{y})$  seja positivo, garantindo que não haja argumentos negativos na função raiz quadrada na Eq. (20).

Por que a distância quadrática tem esse nome?

- Vamos considerar que os vetores  $\mathbf{x}$  e  $\mathbf{y}$  tem dimensão  $p = 2$ , podendo ser representados como

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \quad (23)$$

- Vamos também precisar definir a matriz  $\mathbf{Q}$  como

$$\mathbf{Q} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}, \quad (24)$$

em que  $a, b, c$  e  $d$  são números reais.

Por que a distância quadrática tem esse nome? (cont.)

Assim, substituindo na Eq. (20), temos

$$\begin{aligned} d_q(\mathbf{x}, \mathbf{y}) &= \sqrt{[x_1 - y_1 \ x_2 - y_2] \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \end{bmatrix}}, \quad (25) \\ &= \sqrt{[x_1 - y_1 \ x_2 - y_2] \begin{bmatrix} a(x_1 - y_1) + b(x_2 - y_2) \\ c(x_1 - y_1) + d(x_2 - y_2) \end{bmatrix}}, \end{aligned}$$

que resulta na seguinte expressão:

$$d_q(\mathbf{x}, \mathbf{y}) = \sqrt{a(x_1 - y_1)^2 + (b + c)(x_1 - y_1)(x_2 - y_2) + d(x_2 - y_2)^2}$$

onde se observa a presença de termos elevados ao quadrado.

### Distância quadrática vs. distância euclidiana

- Se fizermos  $\mathbf{Q} = \mathbf{I}_p$  na Eq. (20), obtemos a seguinte expressão:

$$d_q(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^T \mathbf{I}_p (\mathbf{x} - \mathbf{y})} \quad (26)$$

$$= \sqrt{(\mathbf{x} - \mathbf{y})^T (\mathbf{x} - \mathbf{y})} \quad (27)$$

$$= \sqrt{\|\mathbf{x} - \mathbf{y}\|^2} \quad (28)$$

$$= \|\mathbf{x} - \mathbf{y}\|. \quad (29)$$

- De onde podemos concluir que, neste caso particular, a distância quadrática reduz-se à distância euclidiana.

# Parte I

## Normalização dos Dados

### Objetivos

**Objetivo:** Entender a necessidade de equalizar as ordens de grandeza dos atributos usados em um problema de classificação/clusterização.

- **Método 1:** Manter constante a norma dos vetores.
- **Método 2:** Mudança da escala original para os intervalos  $[0, 1]$  ou  $[-1, +1]$ .
- **Método 3:** Padronização dos dados (i.e. média=0, variância=1).

### Método 1: Norma Constante

- Uma das técnicas mais simples de normalização consiste em manter constantes e iguais a 1 as normas dos vetores de atributos  $\mathbf{x}$  e dos centróides  $\mathbf{m}_i$ .
- Este procedimento deve ser aplicado a todos os vetores de atributos e todas os centróides.
- Para isso, basta dividir cada vetor por sua respectiva norma euclidiana:

$$\mathbf{x} = \frac{\mathbf{x}}{\|\mathbf{x}\|} \quad \text{e} \quad \mathbf{m}_i = \frac{\mathbf{m}_i}{\|\mathbf{m}_i\|} \quad (30)$$

### Método 1: Norma Constante

- Por exemplo, considere o seguinte vetor, que não possui norma unitária:

$$\mathbf{x} = \begin{bmatrix} \sqrt{3} \\ 3 \\ -2 \end{bmatrix} \quad (31)$$

- A norma deste vetor é calculada como

$$\|\mathbf{x}\| = \sqrt{(\sqrt{3})^2 + (3)^2 + (-2)^2} = \sqrt{16} = 4. \quad (32)$$

- Assim, a versão normalizada do vetor  $\mathbf{x}$  é dada por

$$\mathbf{x}^* = \frac{\mathbf{x}}{\|\mathbf{x}\|} = \frac{1}{4} \begin{bmatrix} \sqrt{3} \\ 3 \\ -2 \end{bmatrix} = \begin{bmatrix} \sqrt{3}/4 \\ 3/4 \\ -1/2 \end{bmatrix} \quad (33)$$

### Propriedades do Método 1: Norma Constante

- A normalização descrita no slide anterior não altera a direção do vetor, apenas muda seu comprimento.
- Em outras palavras, o vetor resultante é um múltiplo do vetor original conforme pode ser visto na operação a seguir.

$$\mathbf{x}^* = \frac{1}{\|\mathbf{x}\|} \mathbf{x} = \alpha \mathbf{x}, \quad (34)$$

em que  $\alpha = 1/\|\mathbf{x}\|$  é uma constante positiva.

- Note que a normalização assim realizada depende apenas dos valores das componentes do vetor sendo normalizado.
- Assim, chamaremos este tipo de procedimento de normalização local.

### Método 2: Mudança de escala

- A normalização pelo Método 1 é particularmente útil para o classificador de máxima correlação.
- Para classificadores baseados em distância euclidiana, uma normalização que promove uma mudança na escala das variáveis, é mais comum.
- Este procedimento é realizado variável a variável e requer a determinação do valor mínimo ( $x_{min}$ ) e do valor máximo ( $x_{max}$ ) da variável sendo normalizada.
- Por isso, chamaremos este procedimento de normalização global.

# Classificação de Padrões e Medidas de Dissimilaridade

## Normalização dos Dados

Método 2: Mudança de escala para o intervalo [0,1]

$$x^* = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (35)$$




Figura : Mudança da escala original de  $x$  para o intervalo [0,1].

### Método 2: Exemplo 1

- Considere o atributo  $X_1$  (teor alcoólico) do conjunto de dados `wine.dat`.
- Para esta variável temos  $x_{1,min} = 11,03$  e  $x_{1,max} = 14,83$ .
- Assim, a função de normalização é dada por

$$x_1^* = \frac{x_1 - x_{1,min}}{x_{1,max} - x_{1,min}} = \frac{x_1 - 11,03}{14,83 - 11,03} = \frac{x_1 - 11,03}{3,80} \quad (36)$$

- Assim, a observação  $x_1 = 13,50$  na escala original, terá o seguinte valor no intervalo  $[0, 1]$ :

$$x_1^* = \frac{13,50 - 11,03}{3,80} = 0,65. \quad (37)$$

Método 2: Mudança de escala para o intervalo  $[-1, +1]$

$$x^* = 2 \left( \frac{x - x_{min}}{x_{max} - x_{min}} \right) - 1 \quad (38)$$




Figura : Mudança da escala original de  $x$  para o intervalo  $[-1, +1]$ .

### Método 2: Exemplo 2

- Considere o atributo  $X_1$  (teor alcoólico) do conjunto de dados `wine.dat`.
- Para esta variável temos  $x_{1,min} = 11,03$  e  $x_{1,max} = 14,83$ .
- Assim, a função de normalização é dada por

$$x_1^* = 2 \left( \frac{x_1 - x_{1,min}}{x_{1,max} - x_{1,min}} \right) - 1 = 2 \left( \frac{x_1 - 11,03}{3,80} \right) - 1 \quad (39)$$

- Assim, a observação  $x_1 = 13,50$  na escala original, terá o seguinte valor no intervalo  $[-1,+1]$ :

$$x_1^* = 2 \left( \frac{13,50 - 11,03}{3,80} \right) - 1 = 0,30. \quad (40)$$

### Método 3: Padronização da variável (média=0, variância=1)

- Assim como as normalizações descritas no Método 2, devemos aplicar a padronização às variáveis do problema, uma a uma.
- Este tipo de normalização requer o cálculo da média ( $\bar{x}$ ) e do desvio-padrão ( $\sigma_x$ ) da variável  $x$ .
- Por isso, a padronização também pode ser chamada de normalização estatística.
- Este procedimento também é um tipo de normalização global.

# Classificação de Padrões e Medidas de Dissimilaridade

## Normalização dos Dados

### Método 3: Padronização da variável (média=0, variância=1)

- A normalização estatística é dada por

$$x^* = \frac{x - \bar{x}}{\sigma_x} \quad (41)$$

com a média e desvio-padrão amostrais de  $x$  calculados como

$$\bar{x} = \frac{\sum_{n=1}^N x(n)}{N} \quad \text{e} \quad \sigma_x = \sqrt{\left( \frac{\sum_{n=1}^N (x(n) - \bar{x})^2}{N - 1} \right)} \quad (42)$$

tal que  $x(n)$  é a  $n$ -ésima observação de  $x$  e  $N$  é o número total de observações de  $x$ .

### Normalização como Transformação Linear

- As técnicas para normalização de variáveis descritas anteriormente podem ser vistas como uma transformação linear aplicada à variável original.
- Por exemplo, a normalização via Método 2 pode ser escrita da seguinte forma:

$$\begin{aligned}x^* &= \frac{x - x_{min}}{x_{max} - x_{min}} \\&= \left( \frac{1}{x_{max} - x_{min}} \right) x - \left( \frac{x_{min}}{x_{max} - x_{min}} \right) \\&= ax + b\end{aligned}$$

em que  $a = \frac{1}{x_{max} - x_{min}}$  e  $b = -\frac{x_{min}}{x_{max} - x_{min}}$ .

### Propriedade 1 dos Métodos de Normalização

- Por serem transformações lineares, as normalizações descritas anteriormente não alteram a natureza (ou tipo) da distribuição da variável normalizada em relação à variável original não-normalizada.
- Em outras palavras, o tipo de PDF (*probability density function*) da variável permanece o mesmo. Por exemplo, se a PDF for gaussiana, continua gaussiana após a transformação.
- Os parâmetros da PDF podem mudar, mas a forma dela não.
- Este resultado é suportado por um resultado teórico muito importante, que discutiremos a seguir.

### Propriedade 1 dos Métodos de Normalização

- Seja  $x \in \mathbb{R}$  uma variável aleatória contínua, de média  $\mu_x$  e variância  $\sigma_x^2$ , cuja PDF é denotada por  $f_X(x)$ .
- Seja  $y \in \mathbb{R}$  a variável aleatória resultante da seguinte operação matemática sobre  $x$ :  $y = g(x)$ .
- Pode-se mostrar facilmente que a PDF de  $y$  é dada por

$$f_Y(y) = \frac{f_X(x)}{\left| \frac{dy}{dx} \right|} \quad (43)$$

- Assim, para  $y = ax + b$ , com  $a$  e  $b$  constantes reais, tem-se  $|dy/dx| = |a|$  e  $f_Y(y) = |a|f_X(x)$ .
- Além disso, temos que  $\mu_y = E[y] = E[ax + b] = aE[x] + b = a\mu_x + b$ . E também  $\sigma_y^2 = a^2\sigma_x^2$  (demonstrar!)

### Propriedade 2 dos Métodos de Normalização

- Por serem transformações lineares, as normalizações descritas anteriormente não alteram a natureza (ou tipo) da distribuição da variável normalizada em relação à variável original não-normalizada.
- Em outras palavras, o tipo de PDF (*probability density function*) da variável permanece o mesmo. Por exemplo, se a PDF for gaussiana, continua gaussiana após a transformação.
- Como estas técnicas de normalização só utilizam estatísticas descritivas (min, max, média e desvio-padrão) das variáveis, tomadas individualmente, a correlação entre duas variáveis quaisquer permanece a mesma antes e depois da normalização.
- A variável normalizada pelo Método 2, tem a mesma unidade da variável original. Se for normalizada pelo

### Implementação do Método 3 no Excel e LibreOffice Calc

- Dadas  $N$  observações conjuntas de um atributo qualquer, a normalização estatística (ou padronização) podem ser facilmente implementada em planilhas numéricas.
  - No Excel, usar os comandos PADRONIZAR ou NORMALIZAR.
  - No LibreOffice Calc, usar o comando PADRONIZAR.

### Método 3: Exemplo

- Usando o atributo  $X_1$  (teor alcoólico) do conjunto de dados `wine.dat`.
- Para esta variável temos  $\bar{x} = 13,00$  e  $\sigma_1 = 0,81$ .
- Assim, a função de normalização é dada por

$$x_1^* = \frac{x_1 - 13,00}{0,81} \quad (44)$$

- Assim, a observação  $x_1 = 13,50$  na escala original, terá o seguinte valor padronizado:

$$x_1^* = \frac{13,50 - 13,00}{0,81} = 0,617. \quad (45)$$

## Parte II

### Coeficiente de Correlação

# Fundamentos de Correlação

## Objetivos

### Objetivos

**Objetivo:** Entender como duas variáveis estão interrelacionadas do ponto de vista estatístico.


- **Método 1:** Gráfico de dispersão (qualitativo).
- **Método 2:** Coeficiente de Correlação (quantitativo).

**Objetivo:** Discutir relação como modelo de regressão linear simples.

# Fundamentos de Correlação

## Gráfico de Espalhamento (Scatterplot)


- **Correlação Positiva:** ocorre quando um atributo tende a aumentar, o outro também tende a aumentar.



# Fundamentos de Correlação

## Gráfico de Espalhamento (Scatterplot)


- **Correlação Negativa:** ocorre quando um atributo tende a aumentar, o outro também tende a aumentar.



# Fundamentos de Correlação

## Gráfico de Espalhamento (Scatterplot)


- **Correlação Nula [Caso 1:  $\text{var}(X_1)=\text{var}(X_2)$ ]:** não há um padrão definido de tendência.



# Fundamentos de Correlação

## Gráfico de Espalhamento (Scatterplot)

- **Correlação Nula [Caso 2:  $\text{var}(X_1) \neq \text{var}(X_2)$ ]:** também ocorre quando ao aumentar um atributo não há mudança significativa nos valores do outro atributo.



### Definição

- O coeficiente de correlação entre duas variáveis aleatórias quaisquer é dado pela seguinte expressão:

$$\rho_{12} = \frac{\text{cov}(X_1, X_2)}{\text{dp}(X_1) \cdot \text{dp}(X_2)} = \frac{\sigma_{12}}{\sigma_1 \cdot \sigma_2} \quad (46)$$

em que

$$\sigma_{12} = \text{cov}(X_1, X_2) = \text{covariância entre } X_1 \text{ e } X_2.$$

$$\sigma_1 = \text{dp}(X_1) = \text{desvio-padrão de } X_1 = \sqrt{\text{var}(X_1)}$$


$$\sigma_2 = \text{dp}(X_2) = \text{desvio-padrão de } X_2 = \sqrt{\text{var}(X_2)}$$

- Note que:  $-1 \leq \rho(X_1, X_2) \leq 1$ .


# Fundamentos de Correlação

## Coeficiente de Correlação


- Se  $-1 < \rho_{12} < 0$ , então  $X_1$  e  $X_2$  estão **negativamente** correlacionadas.
- Quanto mais próximo  $\rho_{12}$  estiver de -1, maior é a correlação negativa entre  $X_1$  e  $X_2$ .



$$\rho_{12} = -0.98$$



$$\rho_{12} = -0.8$$




$$\rho_{12} = -0.5$$


# Fundamentos de Correlação

## Coeficiente de Correlação


- Se  $0 < \rho_{12} \leq 1$ , então  $X_1$  e  $X_2$  estão **positivamente** correlacionadas.
- Quanto mais próximo  $\rho_{12}$  estiver de 1, maior é a correlação positiva entre  $X_1$  e  $X_2$ .



$$\rho_{12} = 0.5$$



$$\rho_{12} = 0.8$$



$$\rho_{12} = 0.98$$

# Fundamentos de Correlação

## Variância e Desvio-Padrão

- A variância de uma variável aleatória é uma medida de sua dispersão (i.e. espalhamento) em torno de seu valor médio.
- Para um conjunto de  $N$  observações de  $X$  qualquer, sua variância amostral é dada por

$$\sigma_x^2 = \frac{\sum_{n=1}^N (x(n) - \bar{x})^2}{N - 1} \quad (47)$$

em que  $x(n)$  é a  $n$ -ésima observação de  $X$  e  $\bar{x}$  é a média amostral de  $X$  calculada como

$$\bar{x} = \frac{\sum_{n=1}^N x(n)}{N} \quad (48)$$

- O desvio padrão de  $X$  é definido como  $\sigma_x = \sqrt{\sigma_x^2}$ .

# Fundamentos de Correlação

## Covariância

- A covariância entre atributos é a média dos produtos dos desvios de cada atributo em relação às suas respectivas médias.
- Para  $N$  observações conjuntas de  $(X_1, X_2)$ , a covariância amostral entre  $X_1$  e  $X_2$  é dada por

$$\sigma_{12} = \frac{\sum_{n=1}^N (x_1(n) - \bar{x}_1)(x_2(n) - \bar{x}_2)}{N - 1} \quad (49)$$

em que  $x_1(n)$  e  $x_2(n)$  denotam as  $n$ -ésimas observações de  $X_1$  e  $X_2$ , respectivamente; enquanto  $\bar{x}_1$  e  $\bar{x}_2$  são as médias amostrais correspondentes.

- Note que se  $X_1 = X_2$ , temos que  $\sigma_{12} = \sigma_1^2 = \sigma_2^2$ . Ou seja, covariância reduz-se à variância, se  $X_1 = X_2$ .

### Implementação

- Dadas  $N$  observações conjuntas de  $(X_1, X_2)$ , a covariância entre  $X_1$  e  $X_2$  e os desvios-padrão de  $X_1$  e  $X_2$  podem ser facilmente calculados em diferentes softwares.
  - No Matlab/Octave, usar os comandos **cov** e **std**.
  - No Excel<sup>a</sup>, usar os comandos **COVAR** e **DEVPAD**.
  - No LibreOffice Calc, usar os comandos **COVAR** e **DEVPAD**.

---

<sup>a</sup> [www.bertolo.pro.br/matematica/Disciplinas/3ano/Estatistica/Bimestre2/EstatisticaAplicada3.pdf](http://www.bertolo.pro.br/matematica/Disciplinas/3ano/Estatistica/Bimestre2/EstatisticaAplicada3.pdf)

### Implementação

- Dadas  $N$  observações conjuntas de  $(X_1, X_2)$ , o coeficiente de correlação ( $\rho_{12}$ ) também pode ser calculado diretamente em vários pacotes de software.
  - No Matlab/Octave, usar os comandos **corrcoef**.
  - No Excel<sup>a</sup>, usar o comando **CORREL**.
  - No LibreOffice Calc, usar o comando **CORREL**.

---

<sup>a</sup> [www.bertolo.pro.br/matematica/Disciplinas/3ano/Estatistica/Bimestre2/EstatisticaAplicada3.pdf](http://www.bertolo.pro.br/matematica/Disciplinas/3ano/Estatistica/Bimestre2/EstatisticaAplicada3.pdf)

# Fundamentos de Correlação

## Relação entre Correlação e Regressão

- Uma interessante relação teórica entre o gráfico de espalhamento e o coeficiente de correlação pode ser verificada através da inclinação da reta de regressão linear (ou linha de tendência)

$$y = ax + b \quad (\text{ou } x_2 = ax_1 + b), \quad (50)$$

ajustada aos dados pelo método dos mínimos quadrados.

- As constantes  $a$  e  $b$  são chamadas, respectivamente, de inclinação e intercepto da reta de tendência, sendo calculados como

$$\boxed{a = \left( \frac{\sigma_2}{\sigma_1} \right) \rho_{12}} \quad \text{e} \quad \boxed{b = \bar{x}_2 - a\bar{x}_1}. \quad (51)$$

# Fundamentos de Correlação

## Relação entre Correlação e Regressão

- Note que no slide anterior escrevemos a inclinação da reta de regressão como sendo diretamente proporcional ao coeficiente de correlação das variáveis  $X_1$  e  $X_2$ , ou seja

$$a = k \cdot \rho_{12}, \quad (52)$$

em que a constante de proporcionalidade é dada pela razão entre os desvios-padrão de  $X_2$  e  $X_1$ :

$$k = \frac{\sigma_2}{\sigma_1}. \quad (53)$$

- Se os desvios-padrão forem o mesmo para as duas variáveis, temos que a inclinação será igual ao coeficiente de correlação:  $a = \rho_{12}$ , se  $\sigma_1 = \sigma_2$ .

### Implementação

- Dadas  $N$  observações conjuntas de  $(X_1, X_2)$ , a inclinação da linha de tendência ajustada a este conjunto de observações pode ser facilmente calculada em planilhas numéricas.
- No Excel e no LibreOffice Calc, usar o comando **INCLINAÇÃO**.

## Parte III

### Classificador Quadrático

# Classificação de Padrões e Medidas de Dissimilaridade

## Matriz de Covariância

- Costuma-se dispor as covariâncias entre todas as variáveis, tomadas duas a duas,  $\sigma_{ij}$ ,  $i, j = 1, \dots, p$ , em uma *matriz de covariância*,  $\mathbf{C}_x = [\sigma_{ij}]_{p \times p}$ :

$$\mathbf{C}_x = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \cdots & \sigma_p^2 \end{bmatrix}$$

- Os elementos da diagonal principal desta matriz são as variâncias dos  $p$  atributos envolvidos no problema.
- Enquanto fora da diagonal principal tem-se as covariâncias das variáveis  $X_i$  e  $X_j$ , para  $i \neq j$ .

# Classificação de Padrões e Medidas de Dissimilaridade

## Matriz de Covariância

- A matriz de covariância também pode ser escrita como

$$\mathbf{C_x} = \begin{bmatrix} \sigma_1^2 & \rho_{12}\sigma_1\sigma_2 & \cdots & \rho_{1p}\sigma_1\sigma_p \\ \rho_{21}\sigma_2\sigma_1 & \sigma_2^2 & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1}\sigma_p\sigma_1 & \cdots & \cdots & \sigma_p^2 \end{bmatrix}$$

se lembrarmos que o coeficiente de correlação entre  $X_i$  e  $X_j$  é dado por

$$\boxed{\rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \cdot \sigma_j}} \quad (54)$$

de onde tiramos que a covariância entre  $X_i$  e  $X_j$  pode ser expressa como

$$\boxed{\sigma_{ij} = \rho_{ij}\sigma_i\sigma_j} \quad (55)$$

Caso particular:  $\rho_{ij} = 0$

- Quando as correlações entre os atributos são todas nulas (i.e.  $\rho_{ij} = 0, \forall i, j$ ), a matriz de covariância correspondente é diagonal:

$$\mathbf{C_x} = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_p^2 \end{bmatrix}_{p \times p} = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_p^2)$$

Caso particular:  $\rho_{ij} = 0$

- Para este caso particular, o determinante da matriz é facilmente calculado pelo produto dos elementos da diagonal principal:

$$|\mathbf{C}_x| = \sigma_1^2 \cdot \sigma_2^2 \cdots \sigma_p^2 = \prod_{i=1}^p \sigma_i^2 \quad (56)$$

- A inversa de tal matriz também é facilmente calculada

$$\mathbf{C}_x^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 & \cdots & 0 \\ 0 & \frac{1}{\sigma_2^2} & \cdots & 0 \\ \vdots & \cdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{\sigma_p^2} \end{bmatrix}_{p \times p} = \text{diag} \left( \frac{1}{\sigma_1^2}, \frac{1}{\sigma_2^2}, \dots, \frac{1}{\sigma_p^2} \right)$$

### Propriedades da Matriz de Covariância

- 1 A matriz  $\mathbf{C}_x$  é *simétrica*, pois  $\sigma_{ij} = \sigma_{ji}$ :

$$\mathbf{C}_x = \mathbf{C}_x^T$$

- 2 A matriz  $\mathbf{C}_x$  é *definida positiva*:

$$\mathbf{x}^T \mathbf{C}_x \mathbf{x} > 0,$$

para qualquer vetor  $\mathbf{x}$  real e não-nulo.

- 3 Os autovalores  $\lambda_i$  de  $\mathbf{C}_x$  são sempre positivos.
- 4 O determinante de  $\mathbf{C}_x$  é sempre positivo.

### Exercício Resolvido 1 (Matriz de Covariância)

- Dada a seguinte matriz:

$$\mathbf{A} = \begin{bmatrix} 1 & 0,8 \\ 0,8 & 4 \end{bmatrix}$$

- Pede-se determinar se ela pode ser candidata a matriz de covariância.
- **Solução:**
  - ① Logo de cara vemos que a matriz é simétrica!
  - ② Seu determinante é positivo:  $\det(\mathbf{A}) = 3,36$ .
  - ③ E seus autovalores são positivos:  $\lambda_1 = 0,8$  e  $\lambda_2 = 4,2$ .
- Logo, concluímos que a matriz  $\mathbf{A}$  pode de fato ser uma matriz de covariância.

### Matriz de Covariância no Matlab/Octave e no Excel

- Dadas  $N$  observações conjuntas de  $p$  atributos, a matriz de covariância pode ser facilmente calculada em vários ambientes de programação científica (Matlab/Octave) e em planilhas numéricas.
  - No Matlab/Octave, usar o comando **COV**.
  - No Excel, faz-se necessário adicionar um plugin de análise de dados. O tutorial abaixo disponível na internet ensina como fazê-lo.

[www.youtube.com/watch?v=5fEdfQ03g4c](http://www.youtube.com/watch?v=5fEdfQ03g4c)

### Classificador Quadrático

**Passo 1** - Determinar o vetor centróide de cada classe:

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{\forall \mathbf{x} \in \omega_i} \mathbf{x} \quad (57)$$

onde  $N_i$  é o número de exemplos da classe  $\omega_i$ ,  $i = 1, \dots, K$ .

**Passo 2** - Determinar a matriz de covariância de cada classe:

$$\mathbf{C}_i = \frac{1}{N_i} \sum_{\forall \mathbf{x} \in \omega_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T \quad (58)$$


**Passo 3** - Atribuir a  $\mathbf{x}$  a mesma classe que  $\mathbf{m}_{i^*}$ , se

$$(\mathbf{x} - \mathbf{m}_{i^*})^T \mathbf{C}_{i^*}^{-1} (\mathbf{x} - \mathbf{m}_{i^*}) < (\mathbf{x} - \mathbf{m}_i)^T \mathbf{C}_i^{-1} (\mathbf{x} - \mathbf{m}_i), \quad \forall i \neq i^* \quad (59)$$

# Classificação de Padrões e Medidas de Dissimilaridade

## Matriz de Covariância

- Diagrama de fluxo de sinais para o classificador quadrático para um problema de  $K$  classes.



### Distância Quadrática em Classificação e Normalização

- Ao usar da distância quadrática em classificação, não é necessário normalizar os dados previamente.
- Isto é feito automaticamente pela matriz  $\mathbf{C}_i^{-1}$ .
- A título de exemplo, vamos usar apenas 2 atributos.
- Para simplificar, usaremos uma única matriz de covariância para todas as classes:

$$\mathbf{C}_i = \mathbf{C}_{\mathbf{x}} = \text{diag}(\sigma_1^2, \sigma_2^2) = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}. \quad (60)$$

- Deste modo, a matriz inversa é dada por como

$$\mathbf{Q} = \mathbf{C}_{\mathbf{x}}^{-1} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} = \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{bmatrix} \quad (61)$$



### Distância Quadrática em Classificação e Normalização

- Podemos então determinar a distância quadrática de um vetor de atributos  $\mathbf{x}$  para o centróide da  $i$ -ésima classe:

$$\begin{aligned} d_q(\mathbf{x}, \mathbf{m}_i) &= \sqrt{[(x_1 - m_{i1}) \quad (x_2 - m_{i2})] \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{bmatrix} \begin{bmatrix} (x_1 - m_{i1}) \\ (x_2 - m_{i2}) \end{bmatrix}} \\ &= \sqrt{[(x_1 - m_{i1}) \quad (x_2 - m_{i2})] \begin{bmatrix} \frac{(x_1 - m_{i1})}{\sigma_1^2} \\ \frac{(x_2 - m_{i2})}{\sigma_2^2} \end{bmatrix}}, \end{aligned}$$

### Distância Quadrática em Classificação e Normalização

- Que resulta na seguinte expressão:

$$d_q(\mathbf{x}, \mathbf{m}_i) = \sqrt{\left(\frac{x_1 - m_{i1}}{\sigma_1}\right)^2 + \left(\frac{x_2 - m_{i2}}{\sigma_2}\right)^2} \quad (62)$$

- De onde concluímos que, ao usar a distância quadrática, os atributos  $x_1$  e  $x_2$  acabam sendo automaticamente normalizados pelos seus respectivos desvios-padrão!
- Compare os termos da expressão (62) com a expressão da normalização estatística em (41), repetida abaixo:

$$x^* = \frac{x - \bar{x}}{\sigma_x} \quad (63)$$

## Parte IV

### Estimação da Matriz de Covariâcia

### Estimação do Vetor de Médias e da Matriz de Correlação

- Seja um conjunto de  $N$  observações do vetor aleatório  $\mathbf{x} \in \mathbb{R}^p$ :

$$\{\mathbf{x}(1), \mathbf{x}(2), \dots, \mathbf{x}(N)\}$$

- O vetor médio deste conjunto de observações é estimado pela seguinte expressão:

$$\mathbf{m} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}(n) \quad (64)$$

- A matriz de correlação  $\mathbf{R}_x$  é estimada pela seguinte expressão:

$$\hat{\mathbf{R}}_x = \frac{1}{N} \sum_{n=1}^N \mathbf{x}(n) \mathbf{x}^T(n) \quad (65)$$

### Estimação da Matriz de Correlação - Forma Matricial

- Considere que os  $N$  vetores aleatórios estão organizados como sendo as colunas de uma matriz  $\mathbf{X} \in \mathbb{R}^{p \times N}$ :

$$\mathbf{X} = [\mathbf{x}(1) | \mathbf{x}(2) | \cdots | \mathbf{x}(N)] \quad (66)$$

- Desta forma, a matriz de correlação pode ser estimada por meio da seguinte expressão:

$$\hat{\mathbf{R}}_{\mathbf{x}} = \frac{1}{N} \mathbf{X} \mathbf{X}^T \quad (67)$$

- Esta última expressão é particularmente útil na economia de notação matemática e para implementação em ambientes de computação numérica, tais como Matlab, Octave e Scilab.

### Estimação da Matriz de Covariância - Forma Vetorial

- A matriz de covariância pode ser estimada diretamente por meio da seguinte expressão:

$$\hat{\mathbf{C}}_{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N [\mathbf{x}(n) - \mathbf{m}] [\mathbf{x}(n) - \mathbf{m}]^T \quad (68)$$

- Ou então, através da seguinte expressão:

$$\hat{\mathbf{C}}_{\mathbf{x}} = \hat{\mathbf{R}}_{\mathbf{x}} - \mathbf{m}\mathbf{m}^T \quad (69)$$

### Estimação da Matriz de Covariância - Forma Matricial

- Usando a definição da matriz de dados  $\mathbf{X}$ , dada em (66), a matriz de covariância pode ainda ser estimada por meio da seguinte expressão:

$$\hat{\mathbf{C}}_{\mathbf{x}} = \frac{1}{N} [\mathbf{X} - \mathbf{M}] [\mathbf{X} - \mathbf{M}]^T \quad (70)$$

em que  $\mathbf{M} \in \mathbb{R}^{p \times N}$  é uma matriz cujas colunas são formadas pelo vetor médio  $\mathbf{m}$ , repetido  $N$  vezes, ou seja:

$$\mathbf{M} = [\mathbf{m} \mid \mathbf{m} \mid \cdots \mid \mathbf{m}] \quad (71)$$

### Estimação do Vetor de Médias - Forma Recursiva

- A Equação (64) utiliza todos os vetores aleatórios de uma só vez na estimação do vetor  $\bar{\mathbf{X}}$ .
- Em muitos casos, os vetores só estão disponíveis um-a-um, de forma seqüencial. Assim, deve-se estimar tal vetor recursivamente. Por exemplo:

$$\begin{aligned}\mathbf{m}(n) &= \frac{n-1}{n} \mathbf{m}(n-1) + \frac{1}{n} \mathbf{x}(n) \\ &= \alpha \mathbf{m}(n-1) + (1-\alpha) \mathbf{x}(n)\end{aligned}\quad (72)$$

em que  $n$  é a iteração atual,  $\mathbf{x}(n)$  é o vetor sendo observado e  $0 < \alpha < 1$  denota uma constante.

- Em  $n = 0$ , faz-se  $\bar{\mathbf{X}}(0) = \mathbf{0}_p$  = vetor-nulo de dimensão  $p \times 1$ .

### Estimação da Matriz de Correlação - Forma Recursiva

- As técnicas anteriores utilizam todos os vetores aleatórios de uma única vez na estimação das matrizes  $\mathbf{C}_x$  e  $\mathbf{R}_x$ .
- Em muitos casos, os vetores só estão disponíveis um-a-um, de forma seqüencial. Assim, deve-se estimar tais matrizes recursivamente. Por exemplo:

$$\begin{aligned}\hat{\mathbf{R}}_x(n) &= \frac{n-1}{n} \hat{\mathbf{R}}_x(n-1) + \frac{1}{n} \mathbf{x}(n) \mathbf{x}^T(n) \quad (73) \\ &= \alpha \hat{\mathbf{R}}_x(n-1) + (1-\alpha) \mathbf{x}(n) \mathbf{x}^T(n)\end{aligned}$$

em que  $n$  é a iteração atual,  $\mathbf{x}(n)$  é o vetor sendo observado e  $0 < \alpha < 1$  denota uma constante.

- Em  $n = 0$ , faz-se  $\hat{\mathbf{R}}_x(0) = \mathbf{I}_p$  = matriz identidade  $p \times p$ .

### Exemplo no Matlab: Funções nativas `mean()` e `cov()`

- Os comandos a seguir ilustram como determinar o vetor de médias e a matriz de covariância para um conjunto de  $N$  observações de um vetor aleatório gaussiano de dimensão 2:

```
» p=2;      % dim. vetor aleatorio
» N=5000;    % total de observacoes
» X=randn(N, p); % gera vetores aleatorios
» M=mean(X)
M = 0.0097    -0.0027
» Cx=cov(X)
Cx = 1.0224    -0.0124
        -0.0124    0.9887
```

### Exemplo no Matlab: Função `mcovar()`

- A Eq. (68) pode ser implementada pela seguinte rotina:

```
function C=mcovar(X)

[N p]=size(X);
soma=zeros(p);
[N p]=size(X);
M=sum(X)/N; % vetor de medias
for i=1:N,
    soma = soma + (X(i,:)-M)'*(X(i,:)-M);
end
C=soma/N; % Matriz de covariancia
```

- Para executar no Matlab: `» Cx = mcovar(X);`

### Estimando a Matriz de Covariância pela Função `mcovar()`

- A matriz estimada pela rotina `mcovar` é dada por:

```
» Cx=mcovar(X) % Funcao criada no Matlab
```

$$\begin{matrix} \text{Cx} = & 1.0222 & -0.0124 \\ & -0.0124 & 0.9885 \end{matrix}$$

### Exercício Computacional Proposto

- Implementar a Eq. (69) como uma rotina do Matlab chamada `mcovar2` e comparar o resultado com o gerado pela função pronta `cov` e pela rotina `mcovar`.

## Parte V

### Distribuição Gaussiana Multivariada

### FDP Gaussiana Multivariada

- A função densidade de probabilidade gaussiana (ou normal) multivariada é definida pela seguinte expressão:

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\mathbf{C}_{\mathbf{x}}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \mathbf{C}_{\mathbf{x}}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

em que  $|\mathbf{C}_{\mathbf{x}}|$  e  $\mathbf{C}_{\mathbf{x}}^{-1}$  denotam, respectivamente, o determinante e a inversa da matriz de covariância.

- Resumidamente, escrevemos que um vetor aleatório  $\mathbf{x} \in \mathbb{R}^p$  está distribuído segundo uma FDP gaussiana multivariada da seguinte forma:

$$\mathbf{x} \sim N(\boldsymbol{\mu}, \mathbf{C}_{\mathbf{x}})$$



### FDP Gaussiana Multivariada (cont.-1)

- Alternativamente pode-se escrever a FDP gaussiana multivariada como:

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\mathbf{C}_{\mathbf{x}}|^{1/2}} \exp \left\{ -\frac{1}{2} Q(\mathbf{x}) \right\}$$

em que

$$Q(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^T \mathbf{C}_{\mathbf{x}}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

em que a raiz quadrada de  $Q(\mathbf{x})$  é chamada de *Distância de Mahalanobis*.

### FDP Gaussiana Bivariada

- Considerando  $p = 2$ , o vetor aleatório e o vetor de médias passam a ser representados como:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \text{ e } \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} \quad (74)$$

- Logo, a matriz de covariância  $\mathbf{C}_x$  reduz-se a uma matriz quadrada de ordem 2:

$$\mathbf{C}_x = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}_{2 \times 2}$$

### FDP Gaussiana Bivariada (cont.-1)

- Uma forma alternativa da matriz de covariância para o caso bidimensional é dada por:

$$\mathbf{C}_x = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \quad (75)$$

em que  $\rho$  é chamado de *Coeficiente de Correlação* entre  $x_1$  e  $x_2$ :

$$\boxed{\rho = \frac{\sigma_{12}}{\sigma_1\sigma_2}} \quad (76)$$

em que  $\sigma_1$  e  $\sigma_2$  são os desvios-padrões de  $x_1$  e  $x_2$ , respectivamente.

### FDP Gaussiana Bivariada (cont.-2)

- Assim, o determinante da matriz de covariância é dado por:

$$\begin{aligned} |\mathbf{C}_x| &= \begin{vmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{vmatrix} \\ &= \sigma_1^2\sigma_2^2 - (\rho\sigma_1\sigma_2)(\rho\sigma_1\sigma_2) \\ &= (1 - \rho^2)\sigma_1^2\sigma_2^2 \end{aligned} \quad (77)$$

- E a inversa da matriz de covariância é dada por:

$$\mathbf{C}_x^{-1} = \begin{bmatrix} \frac{\sigma_2^2}{|\mathbf{C}_x|} & -\frac{\rho\sigma_1\sigma_2}{|\mathbf{C}_x|} \\ -\frac{\rho\sigma_1\sigma_2}{|\mathbf{C}_x|} & \frac{\sigma_1^2}{|\mathbf{C}_x|} \end{bmatrix} = \begin{bmatrix} \frac{1}{(1-\rho^2)\sigma_1^2} & \frac{-\rho}{(1-\rho^2)\sigma_1^2\sigma_2^2} \\ \frac{-\rho}{(1-\rho^2)\sigma_1^2\sigma_2^2} & \frac{1}{(1-\rho^2)\sigma_2^2} \end{bmatrix}$$

### FDP Gaussiana Bivariada (cont.-3)

- Finalmente, podemos escrever a FDP gaussiana bivariada como:


$$f_{\mathbf{x}}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2}Q(x_1, x_2)\right\}, \quad (78)$$

em que

$$Q(x_1, x_2) = \frac{1}{(1-\rho^2)} \left[ \frac{(x_1 - \mu_1)^2}{\sigma_1^2} - \frac{2\rho(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right]$$

### FDP Gaussiana Bivariada (cont.-4)

- Parâmetros:  $\mu_1 = \mu_2 = 0$ ,  $\sigma_1 = 1$ ,  $\sigma_2 = 2$  e  $\rho = 0,5$ .



### FDPs Marginais da FDP Gaussiana Bivariada

- As PDF gaussianas marginais de  $X_1$  e  $X_2$  são dadas pelas seguintes expressões (Demonstrar!):


$$\begin{aligned}f_{X_1}(x_1) &= \int_{-\infty}^{\infty} f_{\mathbf{x}}(x_1, x_2) dx_2 \\&= \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left\{-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2}\right\} \\f_{X_2}(x_2) &= \int_{-\infty}^{\infty} f_{\mathbf{x}}(x_1, x_2) dx_1 \\&= \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left\{-\frac{(x_2 - \mu_2)^2}{2\sigma_2^2}\right\}\end{aligned}$$

# Variáveis Aleatórias Multidimensionais

## Densidade Gaussiana Bivariada

### FDPs Marginais da FDP Gaussiana Bivariada (cont.-1)

- Parâmetros:  $\mu_1 = \mu_2 = 0$ ,  $\sigma_1 = \sigma_2 = 1$  e  $\rho = 0$ .



### FDPs Condicionais a partir da FDP Gaussiana Bivariada

- PDFs gaussianas condicionais em  $x_1$  ou  $x_2$  podem ser obtidas a partir das seguintes expressões:

$$f_{\mathbf{x}}(x_1|x_2) = \frac{f_{\mathbf{x}}(x_1, x_2)}{f_{x_2}(x_2)} \quad \text{ou} \quad f_{\mathbf{x}}(x_2|x_1) = \frac{f_{\mathbf{x}}(x_1, x_2)}{f_{x_1}(x_1)} \quad (79)$$

- Para um valor específico de  $x_1$  ou  $x_2$ , digamos  $x^*$ , estas expressões podem ser escritas como:

$$f_{\mathbf{x}}(x_1|x_2 = x^*) = \frac{f_{\mathbf{x}}(x_1, x_2 = x^*)}{f_{x_2}(x_2 = x^*)} \quad \text{ou} \quad (80)$$


$$f_{\mathbf{x}}(x_2|x_1 = x^*) = \frac{f_{\mathbf{x}}(x_1 = x^*, x_2)}{f_{x_1}(x_1 = x^*)} \quad (81)$$

# Variáveis Aleatórias Multidimensionais

## Densidade Gaussiana Multivariada

### FDPs Condicionais a partir da FDP Gaussiana Bivariada (cont.-1)

- Parâmetros:  $x_2 = x^* = -1$ ,  $\mu_1 = \mu_2 = 0$ ,  $\sigma_1 = \sigma_2 = 1$  e  $\rho = 0$ .



FDP Gaussiana Bivariada com  $\rho = 0$ .

- Quando  $\rho = 0$ , tem-se as seguintes consequências para a matriz de covariância, seu determinante e sua inversa:

$$\mathbf{C}_x = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix} \Rightarrow |\mathbf{C}_x| = \sigma_1^2 \sigma_2^2$$

$$\mathbf{C}_x^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{bmatrix}$$

### FDP Gaussiana Bivariada com $\rho = 0$ . (cont.-1)

- Note que com  $\rho = 0$ , podemos escrever a FDP gaussiana bivariada como:

$$f_{\mathbf{x}}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2} \exp \left\{ -\frac{1}{2} \left[ \frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\}$$

- Ou seja, podemos escrever:

$$\begin{aligned} f_{\mathbf{x}}(x_1, x_2) &= \frac{1}{\sqrt{2\pi}\sigma_1} e^{\left\{ -\frac{(x_1 - \mu_1)^2}{2\sigma_1^2} \right\}} \cdot \frac{1}{\sqrt{2\pi}\sigma_2} e^{\left\{ -\frac{(x_2 - \mu_2)^2}{2\sigma_2^2} \right\}} \\ &= f_{X_1}(x_1) \cdot f_{X_2}(x_2) \end{aligned} \tag{82}$$

### Não-Correlação e Independência

- **Regra Geral:**

*Se variáveis aleatórias são independentes, então elas também são não-correlacionadas!*

- O raciocínio inverso não é válido:

*Se variáveis aleatórias são não-correlacionadas, isto **não** implica que elas sejam independentes!*

- A Eq. (82) revela uma importante exceção à regra geral:

*Variáveis aleatórias gaussianas não-correlacionadas são **sempre** independentes!!*

## Parte VI

### Contornos da Gaussiana Bivariada

### Contornos da FDP Gaussiana Bivariada

- Vimos que o gráfico da FDP gaussiana bivariada consiste em uma superfície tridimensional.
- Na prática, não há necessidade de desenhar esta superfície toda vez que o interesse for a análise **qualitativa** da correlação entre duas variáveis aleatórias  $x_i$  e  $x_j$ .
- Esta análise, pode ser feita numericamente através do coeficiente de correlação  $\rho_{ij}$ , ou através das **Curvas de Contorno**.

### Contornos da FDP Gaussiana Bivariada

- Uma curva de contorno é a curva formada pelo **lugar geométrico** dos pontos  $(x_1, x_2)$  que satisfazem a equação  $f_{\mathbf{x}}(x_1, x_2) = C$ , em que  $C > 0$  é uma constante.
- Matematicamente, isto é o mesmo que escrever:


$$f_{\mathbf{x}}(x_1, x_2) \propto \exp \left\{ -\frac{1}{2} Q(x_1, x_2) \right\} = C, \quad (83)$$

em que

$$Q(x_1, x_2) = \frac{1}{(1 - \rho^2)} \left[ \frac{(x_1 - \mu_1)^2}{\sigma_1^2} - \frac{2\rho(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1 \sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right]$$

### Contornos da FDP Gaussiana Bivariada (cont.-1)

- Geometricamente, uma curva de contorno é a curva fechada constituída pelo perfil resultante de um corte transversal da superfície  $f_{\mathbf{x}}(x_1, x_2)$  a uma altura  $C$ .



### Contornos da FDP Gaussiana Bivariada (cont.-2)

- Após alguma manipulação algébrica chega-se à seguinte expressão:

$$\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - \frac{2\rho(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} = C \quad (84)$$

- A forma da curva da Eq. (84) depende dos valores de  $\rho$ ,  $\sigma_1$  e  $\sigma_2$ .
- Dois casos de interesse serão estudados a seguir, a saber:
  - ❶ **Variáveis Não-Correlacionadas** ( $\rho = 0$ )
  - ❷ **Variáveis Correlacionadas** ( $\rho \neq 0$ )

### Contornos da FDP Gaussiana Bivariada ( $\rho = 0$ )

- Neste caso, a Eq. (84) reduz-se à seguinte expressão:

$$\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} = C \quad (85)$$

a partir da qual, após dividir ambos os lados por  $C$ , chega-se à *forma canônica* da elipse:

$$\frac{(x_1 - \mu_1)^2}{(\sqrt{C}\sigma_1)^2} + \frac{(x_2 - \mu_2)^2}{(\sqrt{C}\sigma_2)^2} = 1 \quad (86)$$

- Esta elipse tem centro na coordenada  $(\mu_1, \mu_2)$  e os comprimentos dos semi-eixos são dados por  $\sqrt{C}\sigma_1$  e  $\sqrt{C}\sigma_2$ .

### Contornos da FDP Gaussiana Bivariada ( $\rho = 0$ ) (cont.-1)

- Temos 3 casos a considerar:


$\sigma_1 > \sigma_2$  - Elipse com eixo maior ao longo da reta  $x_2 = 0$ , ou seja, mais alongada na horizontal.

$\sigma_1 < \sigma_2$  - Elipse com eixo maior ao longo da reta  $x_1 = 0$ , ou seja, mais alongada na vertical.


$\sigma_1 = \sigma_2$  - Elipse degenerada em uma circunferência.

- A figura no slide a seguir ilustra os três casos supracitados.


### Contornos da FDP Gaussiana Bivariada ( $\rho = 0$ ) (cont.-2)



$$\sigma_1 > \sigma_2$$



$$\sigma_1 < \sigma_2$$



$$\sigma_1 = \sigma_2$$

### Contornos da FDP Gaussiana Bivariada ( $\rho \neq 0$ )

- Neste caso, a Eq. (84), continua representando uma curva de contorno em forma de elipse.
- Contudo, torna-se importante conhecer o efeito introduzido pelo termo

$$-\frac{2\rho(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2}, \quad (87)$$

no desenho da elipse.

- Para facilitar a análise, vamos assumir  $\mu_1 = \mu_2 = 0$  e  $\sigma_1 = \sigma_2 = 1$ .
- Assim, a Eq. (84) passa a ser escrita da seguinte maneira:

$$x_1^2 - 2\rho x_1 x_2 + x_2^2 = C \quad (88)$$

### Contornos da FDP Gaussiana Bivariada ( $\rho \neq 0$ ) (cont.-1)

- A Eq. (88) pode ser reorganizada de tal modo a representar uma equação do segundo grau em  $x_2$ :

$$ax_2^2 + bx_2 + c = 0 \quad (89)$$

em que  $a = 1$ ,  $b = -2\rho x_1$  e  $c = x_1^2 - C_2$ .


- As raízes desta equação são calculadas pela seguinte expressão:

$$x_2 = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} \quad (90)$$

- Usando a Eq. (89), define-se primeiramente uma faixa de valores para  $x_1$  e, em seguida, os valores de  $x_2$  são calculados para cada valor de  $x_1$  usando a Eq. (90).


### Contornos da FDP Gaussiana Bivariada ( $\rho \neq 0$ ) (cont.-2)

- A figura abaixo ilustra uma curva de contorno para variáveis aleatórias  $x_1$  e  $x_2$  correlacionadas positivamente ( $\rho = 0,5$ ).





### Contornos da FDP Gaussiana Bivariada ( $\rho \neq 0$ ) (cont.-3)

- A figura abaixo ilustra uma curva de contorno para variáveis aleatórias  $x_1$  e  $x_2$  correlacionadas negativamente ( $\rho = -0,5$ ).



### Contornos da FDP Gaussiana Bivariada ( $\rho = 0,8$ ) (cont.-4)

- Parâmetros:  $\mu_1 = \mu_2 = 0$ ,  $\sigma_1 = 1$  e  $\sigma_2 = 2$ .



### Geração de Vetores Aleatórios Gaussianos Correlacionados

Passo 1 - Gerar vetores aleatórios gaussianos não-correlacionados:

» `X=randn(p,N);`

Passo 2 - Especificar a matriz de covariância desejada  $\mathbf{C}_d$ :

» `Cd=[1 0.79;0.79 4];`

Passo 3 - Aplicar a Decomposição de Cholesky à matriz  $\mathbf{C}_d$ :

» `A=chol(Cd)';`



Passo 4 - Aplicar transformação linear aos dados originais:

» `Y=A*X;`

Passo 5 - Conferir se a matriz de covariância estimada  $\hat{\mathbf{C}}_d$  está de acordo com a matriz teórica  $\mathbf{C}_d$ .

### Resultados da Aplicação do Algoritmo do Slide Anterior (cont.-1)

- Não-correlacionados (esquerda) e Correlacionados (direita).



### Resultados da Aplicação do Algoritmo do Slide Anterior (cont.-2)

- Para este problema a matriz de covariância estimada  $\hat{\mathbf{C}}_d$  resultante foi:

»  $\mathbf{C}_d = \text{cov}(\mathbf{Y})$

$$\begin{matrix} \mathbf{C}_d = & 0.9983 & 0.7836 \\ & 0.7836 & 3.9609 \end{matrix}$$

- O coeficiente de correlação  $\rho$  teórico é dado por:

$$\rho\sigma_1\sigma_2 = 0,79 \quad \Rightarrow \quad \rho = \frac{0,79}{\sqrt{1}\sqrt{4}} = 0,395$$

- O coeficiente de correlação  $\hat{\rho}$  estimado é dado por:

$$\hat{\rho}\hat{\sigma}_1\hat{\sigma}_2 = 0,7836 \quad \Rightarrow \quad \hat{\rho} = \frac{0,7836}{\sqrt{0,9983}\sqrt{3,9609}} = 0,3941$$



## Parte VII

### Classificação Binária

### Definição

**Classificação binária** é a tarefa de categorizar os elementos de um dado conjunto de objetos em *dois* grupos apenas.

### Aplicações Típicas

- Diagnóstico médico: determinar se um dado indivíduo possui uma doença ou não.
- Controle de qualidade na indústria: decidir se um dado produto é bom o suficiente para ser vendido ou deve ser descartado.
- Detecção de falhas: decidir se um dado equipamento está operando normalmente ou não.

### Conceituação

Em um teste de hipóteses estatístico, o usuário define inicialmente uma *hipótese nula* ( $H_0$ ) e uma *hipótese alternativa* ( $H_1$ ). Em seguida, realiza um experimento e então decide se rejeita  $H_0$  em favor de  $H_1$ .

### Resultados Possíveis

- *Falso Positivo* (erro Tipo I): rejeitar a hipótese nula, quando ela é verdadeira.
- *Verdadeiro Positivo*: rejeitar a hipótese nula, quando ela é falsa.
- *Falso Negativo* (erro Tipo II): aceitar a hipótese nula, quando ela é falsa.
- *Verdadeiro Negativo*: aceitar a hipótese nula, quando ela é verdadeira.



### Conceituação

- Digamos que se queira avaliar pacientes sobre a presença de uma determinada doença ou patologia.
- **Verdadeiros Positivos (VP)**: Pacientes que têm a doença e seus exames acusam corretamente a presença da doença, ou seja, dão positivo.
- **Falsos Negativos (FN)**: Pacientes que têm a doença, porém seus exames não acusam a presença da doença, ou seja, dão negativo.
- **Verdadeiros Negativos (VN)**: Pacientes que não têm a doença e seus exames também não acusam a presença da doença.
- **Falsos Positivos (FP)**: Pacientes que não têm a doença, porém seus exames acusam a presença da mesma.

# Classificação Binária

## Especificidade

### Conceituação

- A **especificidade** é a probabilidade que o exame dê negativo, dado que o paciente não está doente.
- Ou seja, é a razão entre pacientes cujos exames dão negativo (VN) pelo número total de pacientes que são verdadeiramente negativos (VN+FP).
- Quanto maior a especificidade, menor o número de pacientes saudáveis que são classificados com doentes.

### Especificidade (*True Negative Ratio*)

$$\text{Especificidade} = \frac{VN}{VN + FP} \quad (91)$$

### Conceituação

- A **sensibilidade** é a probabilidade que o exame dê positivo, dado que o paciente está doente.
- Ou seja, é a razão entre pacientes cujos exames dão positivo (VP) pelo número total de pacientes que são verdadeiramente positivos (VP+FN).
- Quanto maior a sensibilidade, menor é o número de casos de pacientes doentes que não são detectados.

### Sensibilidade (*True Positive Ratio*)

$$\text{Sensibilidade} = \frac{VP}{VP + FN} \quad (92)$$

### Exemplo

- Testes químicos de gravidez usam uma medida indireta (marcador) para detectar se uma mulher está grávida.
- Tais testes usam a gonadotrofina coriônica (hCG) presente na urina de mulheres grávidas.
- Como a hCG pode ser produzida também por um tumor, a especificidade de um teste moderno de gravidez não pode ser 100%, ou seja, podem ocorrer falsos positivos.
- Além disso, como a hCG está presente em pequenas concentrações após a fertilização e no início da embriogênese, a sensibilidade do teste de gravidez também não pode ser 100%, ou seja, podem ocorrer falsos negativos.

# Classificação Binária

## Matriz de Confusão

### Conceituação

- Em problemas de classificação binária, a *matriz de confusão* é uma tabela com duas linhas e duas colunas que reporta o número de Verdadeiros Negativos, Falsos Positivos, Falsos Negativos e Verdadeiros Positivos.

### Matriz de Confusão para Classificação Binária

		Resultado ou Condição Real	
		Positivo	Negativo
Saída Preditiva	Positivo	VP	FP (erro tipo I, valor $p$ )
	Negativo	FN (erro tipo II)	VN